

# MBA Big Data e Business Intelligence

## Matrizes

Prof. Abraham Laredo Sicsu

## Parte I – definições e operações com R

Tan, Steibach e Kumar (2006):

*“ vector representation brings with it powerful mathematical tools that can be used to represent , transform and analyze data”*

## Matriz de dados

- Cada cliente (uma linha) pode ser representado por um vetor  
**cliente 1 = (376,16,1, 80,1)**
- Cada variável pode ser representada por um vetor
  - **Despesas = (376, 198, . . . , 61)**

CLIENTE	DESPESAS	INTERVALO	ITENS	IDADE	DEPENDENTES
1	376	16	1	80	1
2	198	64	4	56	2
3	84	8	0,5	24	0
4	122	32	2	46	1
5	196	40	2,5	52	3
6	298	48	3	44	2
7	130	40	2,5	30	1
8	138	56	3,5	58	0
9	84	56	3,5	42	0
10	199	96	6	46	0
11	408	64	4	68	1
12	61	56	3,5	34	2

## Definições



### Notas de 5 alunos

Vetor coluna (5 x 1)

$$\mathbf{x} = \begin{bmatrix} 8 \\ 6 \\ 9 \\ 10 \\ 4 \end{bmatrix}$$

vetor linha (1x5) → "transposto" do vetor coluna

$$\mathbf{x}^t = \mathbf{x}' = [8, 6, 9, 10, 4]$$

### Transposição

$\mathbf{x}'$  : vetor transposto de  $\mathbf{x}$

$\mathbf{x}$  : vetor transposto de  $\mathbf{x}'$

Note que os vetores estão em negrito

## Definições



### Soma de vetores

$$\begin{bmatrix} 3 \\ 5 \\ -4 \end{bmatrix} + \begin{bmatrix} 5 \\ 11 \\ 7 \end{bmatrix} = \begin{bmatrix} 8 \\ 16 \\ 3 \end{bmatrix}$$

### Produto por um escalar


$$2 \begin{bmatrix} 3 \\ 5 \\ 9 \end{bmatrix} = \begin{bmatrix} 6 \\ 10 \\ 18 \end{bmatrix} \quad \text{ou} \quad 5(3, 6, 10) = (15, 30, 50)$$

**Vetor nulo:**  $\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$       **vetor unitário:**  $\mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$

## Produto escalar

- Outros nomes : dot product ou produto interno
- Vetores de mesma ordem (nx1)

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} 3 \\ 4 \\ 8 \end{bmatrix} \quad \mathbf{x}' \cdot \mathbf{y} = 1 \times 3 + 2 \times 4 + 3 \times 8 = 35$$




- Produto escalar de um vetor por si mesmo

$$\mathbf{x}' \cdot \mathbf{x} = 1^2 + 2^2 + 3^2 = 14 \quad \text{note que } \mathbf{x}' \cdot \mathbf{x} \geq 0$$

## Módulo de um vetor

- Módulo ou comprimento de um vetor  $\|\mathbf{x}\| = \sqrt{\mathbf{x}' \cdot \mathbf{x}}$  note que  $\mathbf{x}' \cdot \mathbf{x} \geq 0$

$$\mathbf{x} = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \rightarrow \|\mathbf{x}\| = \sqrt{4 + 9} = \sqrt{13} = 3,61$$



## Cálculos com R



```
> a=c(1,2,5)
```

```
> b=c(4,3,8)
```

**produto escalar  $a^t \cdot b$**

# t(a) transposto do vetor a

> t(a) %\*% b # o operador %\*% é para produto de matrizes

```
[,1]
```

```
[1,] 50
```

## Matrizes



- Matriz **A** (3x4)

$$\mathbf{A} = \begin{bmatrix} 2 & 3 & 8 & 5 \\ 6 & 7 & 5 & 9 \\ 2 & 5 & 8 & -1 \end{bmatrix}$$

- Genericamente

$$\mathbf{A} = \begin{pmatrix} a_{11} & \cdots & a_{1p} \\ \vdots & a_{ij} & \vdots \\ a_{n1} & \cdots & a_{np} \end{pmatrix}$$

- Representamos como  $\mathbf{A}_{n \times p} = [a_{ij}]_{n \times p}$

- Transposta de **A** :  $\mathbf{A}'$  ou  $\mathbf{A}^t$  (4x3)  $\rightarrow \mathbf{A}^t = \begin{pmatrix} 2 & 6 & 2 \\ 3 & 7 & 5 \\ 8 & 5 & 8 \\ 5 & 9 & -1 \end{pmatrix}$

## Propriedades da matriz transposta

$$(A^t)^t = A$$

$$(A + B)^t = A^t + B^t$$

$$(A \cdot B)^t = B^t \cdot A^t \quad (\text{veremos produto mais adiante})$$

$$k \in \mathbb{R}; (k \cdot A)^t = k \cdot A^t$$

## Matrizes

- Matriz identidade

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- Matriz diagonal

$$D = \begin{bmatrix} 5 & 0 & 0 \\ 0 & -3 & 0 \\ 0 & 0 & 5 \end{bmatrix} \quad \text{ou } D = \text{diag}(5, -3, 5)$$

- Matriz simétrica

$$A = \begin{bmatrix} 2 & 5 & 7 \\ 5 & 8 & 2 \\ 7 & 2 & 11 \end{bmatrix}$$

- se  $A$  é simétrica  $\rightarrow A^t = A$

## Matriz de correlações

Consideremos o arquivo de dados FREES

INCM	HIGH	OVER	PHYD	BEDP	EXPN
14110,00	68,70	13,40	222,70	3,26	762,21
17829,00	72,30	11,40	239,00	2,87	772,77
13945,00	71,00	11,90	308,00	2,88	653,64
18636,00	72,20	13,80	398,20	3,61	1103,39
15189,00	61,10	14,80	296,70	3,16	851,45
---					

$$r_{xy} = \text{Correlation}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}}$$

```
> print(cor(FREES), digits = 3)
```

	INCM	HIGH	OVER	PHYD	BEDP	EXPN
INCM	1.000	0.405	-0.151	0.702	-0.420	0.265
HIGH	0.405	1.000	-0.305	0.219	-0.524	-0.318
OVER	-0.151	-0.305	1.000	0.109	0.579	0.477
PHYD	0.702	0.219	0.109	1.000	-0.273	0.436
BEDP	-0.420	-0.524	0.579	-0.273	1.000	0.527
EXPN	0.265	-0.318	0.477	0.436	0.527	1.000

## Produto de matrizes

Sejam  $A_{n,p}=(a_{ij})$  e  $B_{p,k}=(b_{ij})$

3	5	1
6	1	2

8	8
4	3
3	0

47	

Se  $X(3 \times 3)$  e  $Y(3 \times 2)$

$XY$  é possível  $\rightarrow C(3 \times 2)$

$YX$  não é possível  $\rightarrow Y(3 \times 2)$   $Y(3 \times 3)$

- Nem sempre é possível obter  $B.A$  (incompatibilidade linhas e colunas)
- Em geral, quando ambas existirem,  $AB \neq BA$ ,
- $(AB)' = B' A'$

Operator or Function	Description
$A * B$	Element-wise multiplication
$A \%*\% B$	Matrix multiplication
$A \%o\% B$	Outer product. $AB^T$
<code>crossprod(A,B)</code>	$A^T B$ and $A^T A$ respectively.
<code>t(A)</code>	Transpose
<code>diag(x)</code>	Creates diagonal matrix with elements of $x$ in the principal diagonal
<code>diag(A)</code>	Returns a vector containing the elements of the principal diagonal
<code>diag(k)</code>	If $k$ is a scalar, this creates a $k \times k$ identity matrix. Go figure.
<code>solve(A, b)</code>	Returns vector $x$ in the equation $b = Ax$ (i.e., $A^{-1}b$ )
<code>solve(A)</code>	Inverse of $A$ where $A$ is a square matrix.
<code>ginv(A)</code>	Moore-Penrose Generalized Inverse of $A$ . <code>ginv(A)</code> requires loading the <b>MASS</b> package.
<code>y&lt;-eigen(A)</code>	<b>y\$val</b> are the eigenvalues of $A$ <b>y\$vec</b> are the eigenvectors of $A$
<code>y&lt;-svd(A)</code>	Single value decomposition of $A$ . <b>y\$d</b> = vector containing the singular values of $A$ <b>y\$u</b> = matrix with columns contain the left singular vectors of $A$ <b>y\$v</b> = matrix with columns contain the right singular vectors of $A$
<code>R &lt;- chol(A)</code>	Choleski factorization of $A$ . Returns the upper triangular factor, such that $R^T R = A$ .
<code>y &lt;- qr(A)</code>	QR decomposition of $A$ . <b>y\$qr</b> has an upper triangle that contains the decomposition and a lower triangle that contains information on the Q decomposition. <b>y\$rank</b> is the rank of $A$ . <b>y\$graux</b> a vector which contains additional information on Q. <b>y\$pivot</b> contains information on the pivoting strategy used.
<code>cbind(A,B,...)</code>	Combine matrices(vectors) horizontally. Returns a matrix.
<code>rbind(A,B,...)</code>	Combine matrices(vectors) vertically. Returns a matrix.
<code>rowMeans(A)</code>	Returns vector of row means.
<code>rowSums(A)</code>	Returns vector of row sums.
<code>colMeans(A)</code>	Returns vector of column means.
<code>colSums(A)</code>	Returns vector of column sums.

## Operações com R

### #geração das matrizes A e B

```
> a1=c(1,5,4)
```

```
> a2=c(6,4,2)
```

```
> A=rbind(a1,a2);A
```

```
  [,1] [,2] [,3]
a1    1    5    4
a2    6    4    2
```

**A(2x3)**

```
> b1=c(2,4)
```

```
> b2=c(1,3)
```

```
> b3=c(5,2)
```

```
> B=rbind(b1,b2,b3);B
```

```
  [,1] [,2]
b1    2    4
b2    1    3
b3    5    2
```

**B(3x2)**



## Operações com R



> t(A)

```
      a1 a2
[1,]  1  6
[2,]  5  4
[3,]  4  2
```

> diag(AB) # vetor com elementos da diagonal

```
[1] 27 40
```

> AB=A%%B ; AB

```
      [,1] [,2]
a1      27  27
a2      26  40
```

Traço de uma matriz :

- soma dos elementos da diagonal

> sum(diag(AB))

```
[1] 67
```

> BA=B%%A ; BA

```
      [,1] [,2] [,3]
b1      26  26  16
b2      19  17  10
b3      17  33  24
```

*Note que  $AB \neq BA$*

## Determinante de uma matriz quadrada



A toda matriz quadrada A corresponde um número  $|A|$ , **determinante da matriz**

Seja a matriz  $A(2 \times 2) = \begin{bmatrix} 5 & 3 \\ 4 & 6 \end{bmatrix}$

$\det(A) = |A| = 5 \times 6 - 3 \times 4 = 18$  (  $|A| = a_{11} \times a_{22} - a_{12} \times a_{21}$  )

- Matrizes de ordem superior a 2x2 → vamos utilizar o R
- Fórmulas : vide livros de álgebra matricial

## Determinante de uma matriz



### Propriedades dos determinantes

1.  $|A| = |A'|$
2.  $A(p \times p) \rightarrow |cA| = c^p |A|$
3.  $\det(AB) = \det(BA) = \det(A)\det(B)$
4. Se  $D = \text{diag}(a_1, a_2, \dots, a_p)$  [matriz diagonal]  $\rightarrow |D| = \prod_1^p a_i$
5.  $|A^{-1}| = 1 / |A|$  (veremos matriz inversa adiante)

## Dependência linear



Os vetores  $x_1, x_2, \dots, x_p$  são **linearmente dependentes** se existirem  $p$  escalares  $k_1, k_2, \dots, k_p$ , não nulos, tais que

$$k_1 x_1 + k_2 x_2 + \dots + k_p x_p = 0$$

Caso contrário são ditos **linearmente independentes**

- Dependência linear causa problemas
  - Redundância entre variáveis: uma variável é combinação linear das demais
  - Multicolinearidade em regressão, por exemplo

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad y = \begin{bmatrix} 3 \\ 4 \\ 8 \end{bmatrix} \quad z = \begin{bmatrix} 22 \\ 32 \\ 60 \end{bmatrix} \quad 2x + 3y + (-0,5)z = 0 \quad 0: \text{vetor nulo}$$

## Cálculo do determinante com R



```
> A=matrix(c(5,3,4,6), nrow = 2);A
```

```
      [,1] [,2]
```

```
[1,]    5    4
```

```
[2,]    3    6
```

Matriz 2x2 de slide anterior

```
> det(A)
```

```
[1] 18
```

```
> x1=c(3,5,12)
```

```
> x2=c(4,2,9)
```

```
> x3=c(8,2,3)
```

```
> X=rbind(x1,x2,x3);X
```

```
      [,1] [,2] [,3]
```

```
x1     3     5    12
```

```
x2     4     2     9
```

```
x3     8     2     3
```

Matriz 3x3 - exemplo

```
> det(X)
```

```
[1] 168
```

## Matriz inversa



A= matriz tal que  $\det(A) \neq 0 \rightarrow$

Existe uma matriz B, única, tal que  $AB=I \rightarrow$  notação  $A^{-1}$

```
> A
```

```
      [,1] [,2] [,3]
```

```
a1     1    -1     1
```

```
a2     2     1     3
```

```
a3     1     1     1
```

```
> det(A)
```

```
[1] -2
```

```
> B=solve(A)
```

```
      a1 a2  a3
```

```
[1,]  1.0 -1  2.0
```

```
[2,] -0.5  0  0.5
```

```
[3,] -0.5  1 -1.5
```

```
> det(B)
```

```
[1] -0.5
```

```
> B*%A
```

```
      [,1] [,2] [,3]
```

```
[1,]    1    0    0
```

```
[2,]    0    1    0
```

```
[3,]    0    0    1
```

## Importante.

### Matriz ortogonal

- A é dita **ortogonal** se  $A^{-1} = A^t \rightarrow (A \cdot A^t) = I$  matriz identidade

### Condição para a existência da inversa de uma matriz:

- A inversa de uma matriz  $A_{p,p}$  existe se as  $p$  colunas da matriz forem linearmente independentes.  $\rightarrow \det(A) \neq 0$ 
  - Se as colunas forem linearmente dependentes,  **$\det(A) = 0$**

## Exercício : Cálculo do determinante com R

```
> x1=c(3,5,13)
> x2=c(4,2,8)
> x3=c(8,2,12)
> X=rbind(x1,x2,x3);X
```

	[,1]	[,2]	[,3]
x1	3	5	13
x2	4	2	8
x3	8	2	12

Note que  
 $\text{vetor}[,3] = \text{vetor}[,1] + 2 \times \text{vetor}[,2]$

```
> det(X)
```

Tente calcular a inversa de X com R

## RANK de uma matriz

### RANK (ordem) de uma matriz $A_{m,p}$

É o número de colunas da matriz que forem vetores linearmente independentes

R tem funções para calcular o rank

## Aplicação – sistemas lineares

É um conjunto de  $m$  ( $m \geq 1$ ) equações lineares nas incógnitas  $x_1, x_2, x_3, \dots, x_n$ .  
O sistema abaixo é dito como sistema linear:

$$\begin{cases} a_{11} \cdot x_1 + a_{12} \cdot x_2 + a_{13} \cdot x_3 + \dots + a_{1n} \cdot x_n = b_1 \\ a_{21} \cdot x_1 + a_{22} \cdot x_2 + a_{23} \cdot x_3 + \dots + a_{2n} \cdot x_n = b_2 \\ a_{31} \cdot x_1 + a_{32} \cdot x_2 + a_{33} \cdot x_3 + \dots + a_{3n} \cdot x_n = b_3 \\ \dots \\ a_{m1} \cdot x_1 + a_{m2} \cdot x_2 + a_{m3} \cdot x_3 + \dots + a_{mn} \cdot x_n = b_m \end{cases}$$

Podemos representar o sistema linear na forma matricial:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & a_{m3} & \dots & a_{mn} \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_m \end{bmatrix}$$

$A \cdot X = B$   
 $A$ : matriz dos coeficientes ( $m \times n$ )  
 $X$ : matriz das incógnitas ( $n \times 1$ )  
 $B$ : matriz dos termos independentes ( $m \times 1$ )

## Sistema lineares – resolução com inversa



Vamos considerar um sistema no qual o número de equações é igual ao número de incógnitas ( $m = n$ ).

Precisamos isolar a matriz  $X$  da equação. Se  $A$  for invertível, temos:

$$A \cdot X = B \rightarrow A^{-1} \cdot A \cdot X = A^{-1} \cdot B \rightarrow I \cdot X = A^{-1} \cdot B \rightarrow X = A^{-1} \cdot B$$

$$\begin{cases} x - y + z = 4 \\ 2 \cdot x + y + 3 \cdot z = 0 \\ x + y + z = 0 \end{cases} \rightarrow \begin{bmatrix} 1 & -1 & 1 \\ 2 & 1 & 3 \\ 1 & 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}$$

Slide do R. Togneri

## Solução com R



```
> a1=c(1,-1,1); a2=c(2,1,3); a3=c(1,1,1)
```

```
> A=rbind(a1,a2,a3)
```

```
> B=c(4,0,0)
```

$$\begin{bmatrix} 1 & -1 & 1 \\ 2 & 1 & 3 \\ 1 & 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 4 \\ 0 \\ 0 \end{bmatrix}$$

```
> Ainv=solve(A)
```

```
> X=Ainv%%B
```

```
> X
```

```
      [,1]
[1,]     4
[2,]    -2
[3,]    -2
```

## Estatística : regressão múltipla (original)



Objetivo: regressão múltipla de y sobre as demais variáveis (n=2000; p=4)

x1	x2	x3	x4	y
26	-8	17	6	426,00
1	26	1	24	753,00
14	-7	8	19	201,00
18	-2	19	3	313,00
-----				

b =

b0
b1
b2
b3
b4

**X=**

1	26	-8	17	6
1	1	26	1	24
1	14	-7	8	19
1	18	-2	19	3

**Y=**

426,00
753,00
201,00
313,00

## Regressão múltipla



$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p$$

Modelo na forma matricial

$$\hat{y} = X \cdot b + \varepsilon$$

Demonstra-se que a solução de mínimos quadrados para estimar  $\beta$  é dada por:

$$b = (X'X)^{-1}X'y$$

$$\hat{y} = Xb = X(X'X)^{-1}X'y = Hy$$

**H**: hat matrix

(demonstração em livros de análise multivariada)

## Exemplo de regressão

(vide script regcommatrizes.R)



Utilizando a função `lm`

```
> sim=SIMULA80_reg
> reg.lm=lm(data = sim, y~.)
> reg.lm
```

Call:

```
lm(formula = y ~ ., data = sim)
```

Coefficients:

(Intercept)	x1	x2	x3	x4
-204.488	38.144	38.756	9.344	8.863

## Exemplo de regressão



```
> simx=model.matrix(data=sim,~.) #gera colunas de "1" na matriz x
> simx=as.data.frame(simx)
> X=simx[,1:5]; X=as.matrix(X)
> Y=simx[6] # forma mais conveniente; melhor que simx [,6]
> Y=as.matrix(Y)
> betas=solve(t(X)%*%X) %*% t(X) %*% Y    b = (X'X)-1X'y
> betas
```

	y
(Intercept)	-204.488127
x1	38.144305
x2	38.756364
x3	9.344195
x4	8.863352



## Exercícios

- Calcule o determinante da matriz seguinte (resp=44)

$$\begin{bmatrix} 6 & 2 & 0 \\ 1 & 4 & 2 \\ 2 & -3 & 0 \end{bmatrix}$$

- Coloque o sistema seguinte na forma matricial e resolva utilizando a matriz inversa dos coeficientes

$$x+y=3;$$

$$2x-6y=-10$$

(resp:  $x=1$   $y=2$ )

- Idem para

$$6x+9y=3;$$

$$2x+3y=5$$

(resp: sistema sem solução)

## Parte II - Autovalores e autovetores

## Transformação de um vetor



Seja a matriz  $A_{n,n}$  e o vetor  $x_{n,1}$

$A \cdot x = y_{n,1} \rightarrow A$  transforma o vetor  $x$  no vetor  $y$

Em geral,  $y$  tem direção diferente de  $x$

> A

	[,1]	[,2]	[,3]
a1	1	-1	1
a2	2	1	3
a3	1	1	1

> x=c(2,3,4)

> A%\*%x

	[,1]
a1	3
a2	19
a3	9

Note que  $x=(2, 3, 4)$  e  $y=(3, 19, 9)$  tem direções distintas

Não existe um escalar  $\lambda$  tal que  $x = \lambda y$

## Autovalores e autovetores



Seja o vetor  $x$  não nulo tal que  $A \cdot x = \lambda x$  onde  $\lambda$  é um escalar

- $A$  transforma  $x$  em outro vetor ( $\lambda x$ ) com mesma direção que  $x$
- Esse vetor  $x$  é denominado **autovetor** (vetor próprio, vetor característico ou **eigenvector**) de  $A$
- $\lambda$  é o **autovalor** (valor próprio, valor característico ou **eigenvalue**) de  $A$  associado a  $x$

## Definição

### Definição 1:

Os autovalores de uma matriz quadrada  $A_{p,p}$  são as raízes da equação (**equação característica**)

$$\det(A - \lambda I) = 0$$

As  $p$  raízes dessa equação são denotadas por  $\lambda_1, \lambda_2, \dots, \lambda_p$ .

- Para cada  $\lambda_i$  existe um vetor  $x$  que satisfaz a equação  $Ax = \lambda_i x$ . Um vetor que satisfaça essa equação é dito **autovetor** de  $A$  associado a  $\lambda$  (a demonstração não será apresentada aqui). Pode ser  $x$  ou múltiplo de  $x$ , **não nulo**
- $\lambda$  pode ser nulo
- Os **autovalores** podem ser números reais ou complexos.
  - Se  $A$  for simétrica todos os autovalores serão números reais**
  - Caso usual em aplicações estatísticas**

## Exemplo 1

> W

```
      [,1] [,2]
[1,]    1    5
[2,]    2    4
```

> eigen(W)

```
eigen() decomposition
$values
[1]  6 -1
```

R dá em ordem  
decrecente

\$vectors

	[,1]	[,2]
[1,]	-0.7071068	-0.9284767
[2,]	-0.7071068	0.3713907

Autovetores padronizados  
Módulo=1

## Exercícios

- Defina no R os vetores

`v1=eigen(W)$vectors[,1]` #1º autovetor de W

`v2=eigen(W)$vectors[,2]` #2º autovetor de W

- Calcule os produtos

`a1=W %*% v1`

`a2 = W %*% v2`

```
$vectors
      [,1]      [,2]
[1,] -0.7071068 -0.9284767
[2,] -0.7071068  0.3713907
```

- Compare **a1** e **a2** com **v1** e **v2** respectivamente

## Exemplo 2

**> Q**

```
      [,1] [,2]
```

```
[1,]  1  -2
```

```
[2,]  2   4
```

**> eigen(Q)**

eigen() decomposition

\$values

```
[1] 2.5+1.322876i 2.5-1.322876i
```

*Valores complexos*

\$vectors

```
      [,1]      [,2]
```

```
[1,] -0.5303301+0.4677072i -0.5303301-0.4677072i
```

```
[2,] 0.7071068+0.0000000i 0.7071068+0.0000000i
```

### Exemplo 3

> D

	[,1]	[,2]	[,3]
a	1	0	0
b	0	1	0
c	0	0	3

> eigen(D)

eigen() decomposition

\$values

[1] 3 1 1

\$vectors

	[,1]	[,2]	[,3]
[1,]	0	0	1
[2,]	0	1	0
[3,]	1	0	0

*Matriz diagonal  
Os autovalores são os valores  
da diagonal*

### Matriz simétrica

> A

	[,1]	[,2]
[1,]	0.8	0.2
[2,]	0.2	0.7

> eigen(A)

eigen() decomposition

\$values

[1] 0.9561553 0.5438447

\$vectors

	[,1]	[,2]
[1,]	-0.7882054	0.6154122
[2,]	-0.6154122	-0.7882054

*Autovetores  
ortogonais*

#### Exercício

- Determine os vetores  
 $v1 = \text{eigen}(A)\$vectors[,1]$   
 $v2 = \text{eigen}(A)\$vectors[,2]$

- Calcule o produto  $v1^t v2$   
 $t(v1) \%*\% v2$

- O que significa o resultado ?

## PROPRIEDADES



- 1) O produto dos autovalores é igual ao determinante da matriz
- 2) Uma matriz  $\mathbf{A}$  é singular [ $\det(\mathbf{A}) = 0$ ] sse possuir um autovalor nulo
- 3) A soma dos autovalores é igual ao traço da matriz
- 4) Se  $\lambda$  for um autovalor de  $\mathbf{A}$  e  $\mathbf{A}$  for invertível,  $1/\lambda$  é um auto valor de  $\mathbf{A}^{-1}$
- 5) Se  $\lambda$  for um autovalor de  $\mathbf{A}$ ,  $\lambda$  será um auto valor de  $\mathbf{A}^t$
- 6) Se  $\mathbf{A}$  for simétrica, os autovetores  $\mathbf{x}_a$  e  $\mathbf{x}_b$  correspondentes a autovalores distintos  $\lambda_a$  e  $\lambda_b$  ( $\lambda_a \neq \lambda_b$ ) são ortogonais, i.e.,  $\mathbf{x}_a^t \mathbf{x}_b = 0$
- 7) Decomposição espectral de  $\mathbf{A}$  : Toda matriz simétrica pode ser escrita como  $\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^t$  onde :

$\mathbf{\Lambda}$  é uma matriz diagonal cujos elementos são os autovalores de  $\mathbf{A}$

$\mathbf{P}$  é uma matriz ortogonal ( i.e.,  $\mathbf{P} \cdot \mathbf{P}^t = \mathbf{I}$ ) cujas colunas são os autovetores padronizados (módulo 1) associados com as entradas na diagonal de  $\mathbf{\Lambda}$

## Autovalores de uma matriz de correlações



> head(IRIS)

	sepal_length	sepal_width	petal_length	petal_width
1	5.1	3.5	1.4	0.2
2	4.9	3.0	1.4	0.2
3	4.7	3.2	1.3	0.2
4	4.6	3.1	1.5	0.2
5	5.0	3.6	1.4	0.2
6	5.4	3.9	1.7	0.4

> R=cor(IRIS) # em geral a matriz de correlações é denotada por R

> R

	sepal_length	sepal_width	petal_length	petal_width
sepal_length	1.0000000	-0.1093692	0.8717542	0.8179536
sepal_width	-0.1093692	1.0000000	-0.4205161	-0.3565441
petal_length	0.8717542	-0.4205161	1.0000000	0.9627571
petal_width	0.8179536	-0.3565441	0.9627571	1.0000000

## Autovalores e autovetores de R



> EIG=eigen(R)

> EIG\$values

[1] 2.91081808 0.92122093 0.14735328 0.02060771

> AV=EIG\$vectors

> AV

	[,1]	[,2]	[,3]	[,4]
[1,]	0.5223716	-0.37231836	0.7210168	0.2619956
[2,]	-0.2633549	-0.92555649	-0.2420329	-0.1241348
[3,]	0.5812540	-0.02109478	-0.1408923	-0.8011543
[4,]	0.5656110	-0.06541577	-0.6338014	0.5235463

> round(t(AV)%\*%AV,5)

	[,1]	[,2]	[,3]	[,4]
[1,]	1	0	0	0
[2,]	0	1	0	0
[3,]	0	0	1	0
[4,]	0	0	0	1

	$v_1$	$v_2$	$v_3$	$v_4$
$v_1^t$	1	0	0	0
$v_2^t$	0	1	0	0
$v_3^t$	0	0	1	0
$v_4^t$	0	0	0	1

## Autovalores e autovetores de R



- Note que
  - Os autovalores são reais e maiores que zero
  - Autovetores são ortogonais
  - A matriz pode ser decomposta como segue:

$$R = AV \cdot D \cdot AV^t$$

- AV matriz dos autovetores
- D Matriz diagonal cujos elementos são os autovalores de A
- (decomposição spectral de A)

Estes resultados valem para toda matriz de correlações e toda matriz de covariâncias

Operator or Function	Description
$A * B$	Element-wise multiplication
$A \%*\% B$	Matrix multiplication
$A \%o\% B$	Outer product. $AB^T$
<code>crossprod(A,B)</code>	$A^T B$ and $A^T A$ respectively.
<code>t(A)</code>	Transpose
<code>diag(x)</code>	Creates diagonal matrix with elements of $x$ in the principal diagonal
<code>diag(A)</code>	Returns a vector containing the elements of the principal diagonal
<code>diag(k)</code>	If $k$ is a scalar, this creates a $k \times k$ identity matrix. Go figure.
<code>solve(A, b)</code>	Returns vector $x$ in the equation $b = Ax$ (i.e., $A^{-1}b$ )
<code>solve(A)</code>	Inverse of $A$ where $A$ is a square matrix.
<code>ginv(A)</code>	Moore-Penrose Generalized Inverse of $A$ . <code>ginv(A)</code> requires loading the <b>MASS</b> package.
<code>y&lt;-eigen(A)</code>	<b>y\$val</b> are the eigenvalues of $A$ <b>y\$vec</b> are the eigenvectors of $A$
<code>y&lt;-svd(A)</code>	Single value decomposition of $A$ . <b>y\$d</b> = vector containing the singular values of $A$ <b>y\$u</b> = matrix with columns contain the left singular vectors of $A$ <b>y\$v</b> = matrix with columns contain the right singular vectors of $A$
<code>R &lt;- chol(A)</code>	Choleski factorization of $A$ . Returns the upper triangular factor, such that $R^T R = A$ .
<code>y &lt;- qr(A)</code>	QR decomposition of $A$ . <b>y\$qr</b> has an upper triangle that contains the decomposition and a lower triangle that contains information on the Q decomposition. <b>y\$rank</b> is the rank of $A$ . <b>y\$graux</b> a vector which contains additional information on Q. <b>y\$pivot</b> contains information on the pivoting strategy used.
<code>cbind(A,B,...)</code>	Combine matrices(vectors) horizontally. Returns a matrix.
<code>rbind(A,B,...)</code>	Combine matrices(vectors) vertically. Returns a matrix.
<code>rowMeans(A)</code>	Returns vector of row means.
<code>rowSums(A)</code>	Returns vector of row sums.
<code>colMeans(A)</code>	Returns vector of column means.
<code>colSums(A)</code>	Returns vector of column sums.